

# Datenbasierte Startup Auswahl

---

Startup Growth & Funding Trends



# Agenda



1. Business Understanding & Datenexploration
  - 1.1 Business Context
  - 1.2 Relevanz von Data Science
  - 1.3 Explorative Datenanalyse
  - 1.4 Statistische Analyse
  - 1.5 potenzielle Verzerrungen
2. Datenaufbereitung
3. Modellierung & Evaluation
4. Geschäftsempfehlungen & Kritische Reflexion
  - 4.1 Geschäftsempfehlungen
  - 4.2. Kritische Reflexion

# 1.1 Business Context



## Unser Ziel:

→ Wir möchten anhand des Datensatzes, **große Mengen an Startups ressourceneffizient** für Investoren **bewerten**, um mögliche Unicorns zu identifizieren



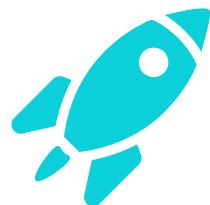
1. Welche Kennzahlen beeinflussen die Profitabilität für Investoren?
2. Wie gut kann ein datenbasiertes Modell Vorhersagen über die Profitabilität von Start-ups treffen?

# 1.2 Inwiefern ist Data Science relevant?



**Weniger psychologische Verzerrungen**

Confirmation Bias  
Halo-Effekt  
Recency Bias



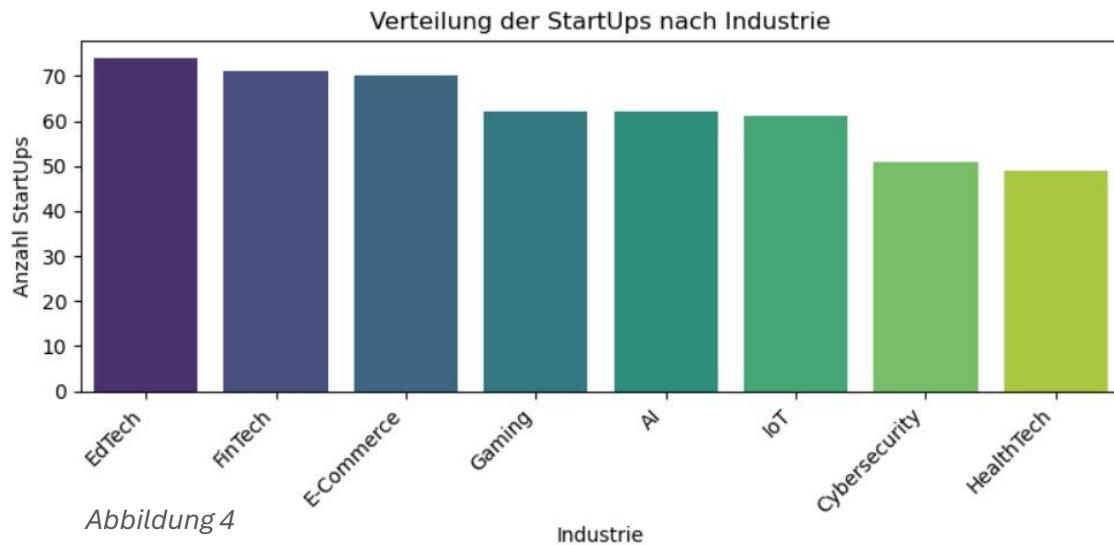
**Überblick über große Start-up Mengen verschaffen**



**Besonders relevante und risikoarme Start-ups rausfiltern**

→ Chancen und Risiken werden faktenbasiert und objektiv bewertet

# 1.3 Explorative Datenanalyse



Verteilung nach Region  
Verteilung der StartUps nach Region

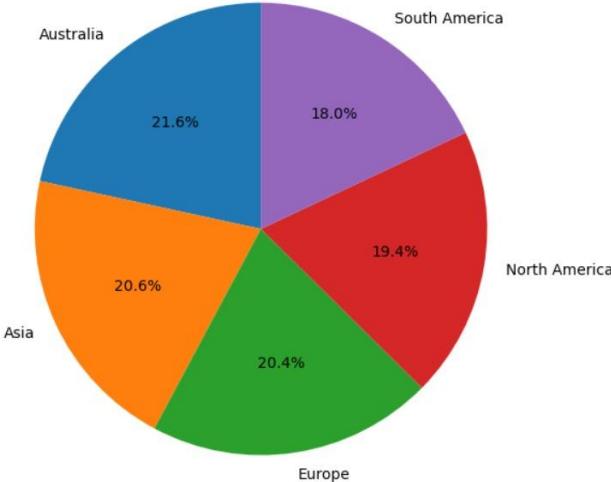
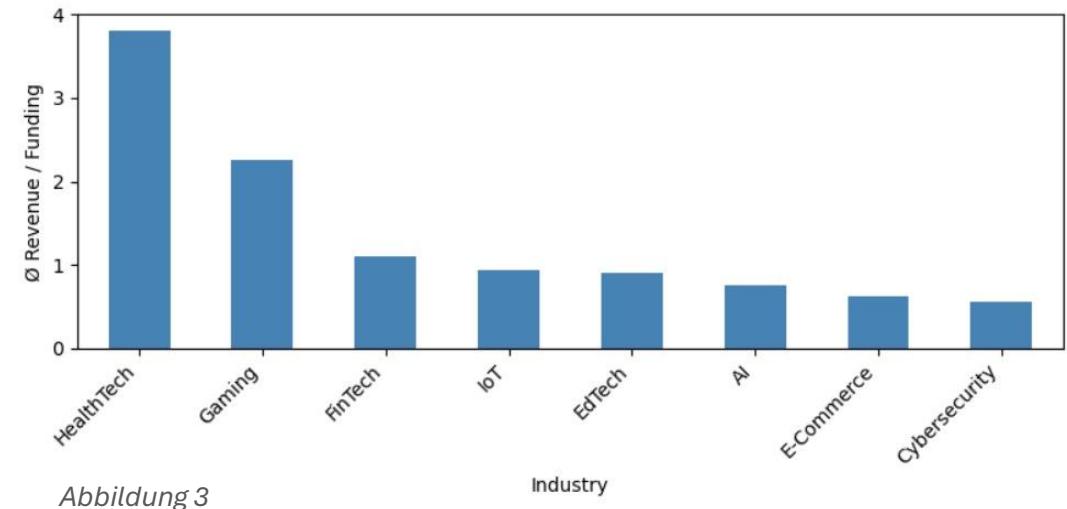


Abbildung 2

Umsatzeffizienz nach Branche



# 1.4 Statistische Analyse

- Korrelationsmatrix zeigt, wie 2 Variablen zusammenhängen
- Dabei gilt: **Korrelation  $\neq$  Kausalität**
- Bei 500 Start-ups sind Werte  $> 0,088$  mathematisch „echt“
- Bei Korrelationswerten von...
  - ...0,3 und kleiner ist der Effekt klein
  - ... 0,5 und größer ist der Effekt stark

→ Lösung der Geschäftsfragen durch Korrelationsanalyse nicht möglich

→ trotzdem relevant in Verbindung mit Feature Engineering

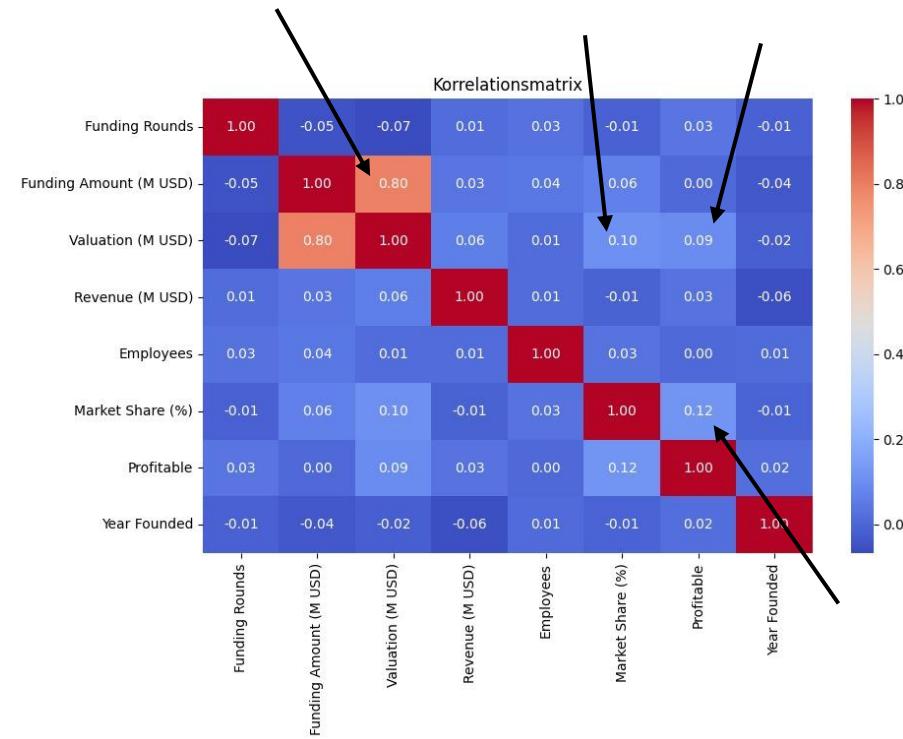


Abbildung 5

# 1.5 Potenzielle Verzerrungen im Datensatz

- ☒ Kleine Stichprobe
- 🛡 Survivorship Bias
- 📍 Regional/Branchen-Bias
- ⌚ Zeitlicher Bias
- 🔍 Erfolgskonzentration
- ✖ Qualitative Daten
- 👉 Vage Definitionen

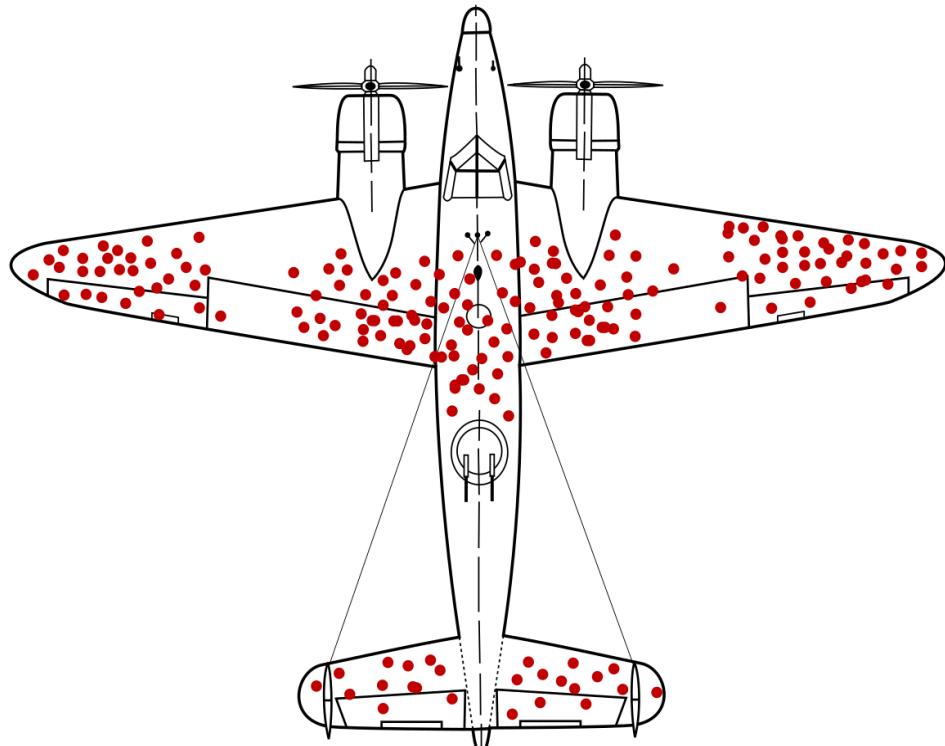


Abbildung 6

## 2. Fehlende Werte & Ausreißer

### Fehlende Werte

- Ergebnis der Analyse:
  - Keine fehlenden Werte
- Interpretation & Bedeutung:
  - Außergewöhnliche Qualität
  - Hohe Zuverlässigkeit
- Konsequenzen für die Analyse:
  - Keine Imputation nötig
  - Kein Informationsverlust
  - Vereinfachte Modellierung

### Ausreißer

- Hervorragende Datenqualität:
  - Extrem niedrige Ausreißerrate (0,2%)
  - Keine weiteren Anomalien
- Einzelausreißer Startup 385:
  - Valuation mit 5.357,49 Mio. USD
  - Abweichung: Marginal
- Handlung:
  - Beibehalten
  - Start-up-Ökosystem: Extremwerte sind Branchenüblich

# 3. Modellierung & Evaluation

## Modellauswahl

- Decision Tree
  - Interpretierbarkeit
  - Umgang mit nichtlinearen Zusammenhängen
  - Klares Bias/Varianz-Verhalten

## Evaluation

- ROC-AUC
- Confusion Matrix
- Kontextbezogene Metriken

# Alternativen?

---

# 4.1 Geschäftsempfehlungen

## Was bedeutet das?

- Pipeline zur Datenvorverarbeitung
- Decision Tree:
  - Baum aus Entscheidungsregeln
- Wie geht man mit den Werten um?

## Was tun?

- **NICHT!** Blind investieren
- Empfehlungen sollen helfen
- Daten nach dem Invest nutzen

## Wo sind die Grenzen?

- Datenqualität
- Features
- Modell
- Sonstiges

| Startup Name | Industry      | Region        | Prob. Profit | Prognose (y_pred) | Realität (y_actual) |
|--------------|---------------|---------------|--------------|-------------------|---------------------|
| Startup_78   | Cybersecurity | Australia     | 0.689        | 1                 | 1                   |
| Startup_289  | Gaming        | Australia     | 0.689        | 1                 | 1                   |
| Startup_330  | Gaming        | Asia          | 0.689        | 1                 | 1                   |
| Startup_14   | Cybersecurity | South America | 0.689        | 1                 | 0                   |
| Startup_234  | Gaming        | North America | 0.689        | 1                 | 0                   |
| Startup_8    | HealthTech    | Australia     | 0.689        | 1                 | 1                   |
| Startup_208  | Gaming        | Asia          | 0.689        | 1                 | 1                   |
| Startup_218  | E-Commerce    | Europe        | 0.689        | 1                 | 1                   |
| Startup_418  | E-Commerce    | North America | 0.689        | 1                 | 1                   |
| Startup_192  | Cybersecurity | Asia          | 0.689        | 1                 | 0                   |

Abbildung 7

## 4.2 Kritische Reflexion

-  **Survivorship Bias?** Fehlen gescheiterte Startups? Datensatz repräsentativ für gesamtes Marktgeschehen?
-  **Modell-Performance?** Sind 60% Accuracy / 35% Recall besser als zufälliges Raten? Wo liegt die Schwäche?
-  **Kausalität vs. Korrelation?** Führt Funding zu Erfolg oder erhalten erfolgreiche Startups mehr Funding (Selection Bias)?
-  **Zeitliche Validität?** Direkter Vergleich von Startups über 30 Jahre hinweg (Kohorteneffekte) ohne Normalisierung sinnvoll?
-  **Umsetzbare Hebel?** Sind Empfehlungen für Investoren oder Gründer überhaupt konkret steuer- und umsetzbar?
-  **Qualitative Faktoren?** Wie werden Faktoren wie Teamqualität, Vision und Anpassungsfähigkeit bewertet, die nicht im Datensatz sind?

# Abbildungen

1. <https://www.datascience-pm.com/wp-content/uploads/2021/02/CRISP-DM.png.webp>
2. Verteilung nach Regionen mithilfe der Mathplotlib-Bibliothek erstellt
3. Verteilung nach Branchen mithilfe der Mathplotlib-Bibliothek erstellt
4. Umsatzeffizienz nach Branchen mithilfe der Mathplotlib-Bibliothek erstellt
5. Korrelationsmatrix mithilfe der Mathplotlib erstellt
6. <https://upload.wikimedia.org/wikipedia/commons/thumb/b/b2/Survivorship-bias.svg/1280px-Survivorship-bias.svg.png>
7. Tabelle